

Analiza incydentów cyberbezpieczeństwa z lat 2015–2024 z zastosowaniem metod eksploracji danych

Aleksandra Barycka

1 Opis i eksploracja danych

1.1 Podstawowe informacje

Wybrany przez nas zbiór danych przedstawia informacje o globalnych incydentach związanych z cyberbezpieczeństwem, zarejestrowanych w latach 2015–2024. Dane te mogą być pomocne w analizie zagrożeń, identyfikacji trendów oraz ocenie skuteczności mechanizmów obronnych stosowanych przez organizacje. Każdy wiersz w zbiorze reprezentuje pojedynczy incydent i zawiera zestaw atrybutów opisujących kontekst zdarzenia, jego charakter, skalę oraz skutki. Dane mają charakter przekrojowy i obejmują zarówno zmienne kategoryczne, jak i liczbowe.

| | Country | Year | Attack Type | Target Industry | Financial Loss (in Million \$) | Number of Affected Users | Attack Source | Security Vulnerability Type | Defense Mechanism Used | Incident Resolution Time (in Hours) |
|---|---------|------|-------------------|--------------------|--------------------------------|--------------------------|---------------|-----------------------------|------------------------|-------------------------------------|
| 0 | China | 2019 | Phishing | Education | 80.53 | 773169 | Hacker Group | Unpatched Software | VPN | 63 |
| 1 | China | 2019 | Ransomware | Retail | 62.19 | 295961 | Hacker Group | Unpatched Software | Firewall | 71 |
| 2 | India | 2017 | Man-in-the-Middle | IT | 38.65 | 605895 | Hacker Group | Weak Passwords | VPN | 20 |
| 3 | UK | 2024 | Ransomware | Telecommunications | 41.44 | 659320 | Nation-state | Social Engineering | AI-based Detection | 7 |
| 4 | Germany | 2018 | Man-in-the-Middle | IT | 74.41 | 810682 | Insider | Social Engineering | VPN | 68 |

Wyświetlanie pierwszych 5 rekordów w zbiorze danych

| Kolumna | Opis |
|-------------------------------------|---|
| Country | Kraj, w którym odnotowano atak |
| Year | Rok incydentu |
| Attack Type | Rodzaj ataku (np. phishing, ransomware) |
| Target Industry | Branża będąca celem |
| Financial Loss (in Million \$) | Straty finansowe w milionach dolarów |
| Number of Affected Users | Liczba użytkowników, których dotknął incydent |
| Attack Source | Kto stoi za atakiem (np. grupa hakerska, insider) |
| Security Vulnerability Type | Rodzaj wykorzystanej luki |
| Defense Mechanism Used | Zastosowane mechanizmy obronne |
| Incident Resolution Time (in Hours) | Czas rozwiązania incydentu |

Opis poszczególnych kolumn w zbiorze danych

1.2 Typy danych

Zbiór danych składa się z 10 atrybutów, obejmujących zarówno zmienne liczbowe, jak i kategoryczne. Zmienne liczbowe to m.in.: rok zdarzenia (*Year*), straty finansowe (*Financial Loss*), liczba poszkodowanych użytkowników (*Number of Affected Users*) oraz czas rozwiązania incydentu (*Incident Resolution Time*). Pozostałe kolumny, takie jak kraj, typ ataku czy branża docelowa, mają charakter kategoryczny.

```

Typy danych:
Country          object
Year             int64
Attack Type      object
Target Industry  object
Financial Loss (in Million $) float64
Number of Affected Users int64
Attack Source    object
Security Vulnerability Type object
Defense Mechanism Used object
Incident Resolution Time (in Hours) int64
dtype: object

```

Typy danych w zbiorze

1.3 Braki danych

Analiza braków danych wykazała, że zbiór jest kompletny – żadna z kolumn nie zawiera brakujących wartości. Zapewnia to wysoką jakość danych wejściowych i umożliwia przeprowadzenie dalszych analiz bez konieczności uzupełniania lub imputacji danych.

```

Braki danych:
Country          0
Year             0
Attack Type      0
Target Industry  0
Financial Loss (in Million $) 0
Number of Affected Users 0
Attack Source    0
Security Vulnerability Type 0
Defense Mechanism Used 0
Incident Resolution Time (in Hours) 0
dtype: int64

```

Braki danych w zbiorze

1.4 Opis statystyczny zmiennych liczbowych

Wartości liczbowe zostały poddane analizie statystycznej, co pozwala ocenić rozkład i zmienność danych:

- **Rok zdarzenia:** dane obejmują lata 2015–2024, ze średnią 2019,6.
- **Straty finansowe:** średnia strata wynosi ok. 50,5 mln USD, przy dużym rozrzucie (od 0,5 mln do 99,99 mln USD).
- **Liczba poszkodowanych użytkowników:** średnio ok. 504 tys. użytkowników na incydent, z dużą zmiennością (od 424 do niemal miliona).
- **Czas rozwiązania incydentu:** przeciętnie 36,5 godziny, z rozrzutem od 1 do 72 godzin, co wskazuje na zróżnicowaną skuteczność reakcji na incydenty.

Opis statystyczny:

| | Year | Financial Loss (in Million \$) | Number of Affected Users |
|-------|-------------|--------------------------------|--------------------------|
| count | 3000.000000 | 3000.000000 | 3000.000000 |
| mean | 2019.570333 | 50.492970 | 504684.136333 |
| std | 2.857932 | 28.791415 | 289944.084972 |
| min | 2015.000000 | 0.500000 | 424.000000 |
| 25% | 2017.000000 | 25.757500 | 255805.250000 |
| 50% | 2020.000000 | 50.795000 | 504513.000000 |
| 75% | 2022.000000 | 75.630000 | 758088.500000 |
| max | 2024.000000 | 99.990000 | 999635.000000 |

| | Incident Resolution Time (in Hours) |
|-------|-------------------------------------|
| count | 3000.000000 |
| mean | 36.476000 |
| std | 20.570768 |
| min | 1.000000 |
| 25% | 19.000000 |
| 50% | 37.000000 |
| 75% | 55.000000 |
| max | 72.000000 |

Statystyki opisowe zmiennych liczbowych

1.5 Najczęstsze wartości w kategoriach

Analiza najczęstszych wartości w kategoriach pozwala zidentyfikować dominujące trendy:


- **Kraje:** Najwięcej incydentów odnotowano w Wielkiej Brytanii, Brazylii, Indiach, Japonii i Francji.
- **Typy ataków:** Najczęstsze to DDoS, phishing, SQL Injection, ransomware i malware.
- **Branże docelowe:** Najczęściej atakowane są sektory IT, bankowość, opieka zdrowotna, handel detaliczny i edukacja.
- **Źródła ataków:** Przeważają ataki ze strony państw narodowych, nieznanych źródeł, insiderów oraz grup hakerskich.
- **Typy podatności:** Najczęściej wykorzystywane są podatności typu zero-day, social engineering, niezaktualizowane oprogramowanie oraz słabe hasła.
- **Mechanizmy obronne:** Najczęściej stosowane są: antywirusy, VPN, szyfrowanie, firewalle i detekcja oparta na AI.

| | |
|---------------------------|--------------------------------------|
| Country - Top 5: | Attack Source - Top 5: |
| Country | Attack Source |
| UK 321 | Nation-state 794 |
| Brazil 310 | Unknown 768 |
| India 308 | Insider 752 |
| Japan 305 | Hacker Group 686 |
| France 305 | Name: count, dtype: int64 |
| Name: count, dtype: int64 | Security Vulnerability Type - Top 5: |
| Attack Type - Top 5: | Security Vulnerability Type |
| Attack Type | Zero-day 785 |
| DDoS 531 | Social Engineering 747 |
| Phishing 529 | Unpatched Software 738 |
| SQL Injection 503 | Weak Passwords 730 |
| Ransomware 493 | Name: count, dtype: int64 |
| Malware 485 | Defense Mechanism Used - Top 5: |
| Name: count, dtype: int64 | Defense Mechanism Used |
| Target Industry - Top 5: | Antivirus 628 |
| Target Industry | VPN 612 |
| IT 478 | Encryption 592 |
| Banking 445 | Firewall 585 |
| Healthcare 429 | AI-based Detection 583 |
| Retail 423 | Name: count, dtype: int64 |
| Education 419 | |
| Name: count, dtype: int64 | |

Najczęstsze wartości w kategoriach (Top 5)

1.6 Liczba incydentów cyberbezpieczeństwa w latach 2015–2024


Na poniższym wykresie zaprezentowano liczbę incydentów cyberbezpieczeństwa zarejestrowanych w kolejnych latach badanego okresu. Z wykresu wynika, że liczba incydentów utrzymuje się na wysokim poziomie przez cały analizowany okres, z zauważalnym wzrostem w latach 2016–2017 oraz odbiciem po spadku w roku 2019. Trend ten może odzwierciedlać zarówno wzrost liczby ataków, jak i poprawę w zakresie ich wykrywania i raportowania. Rok 2019 charakteryzuje się spadkiem liczby incydentów, co może wynikać z chwilowej poprawy zabezpieczeń lub niedoszacowania raportów.



Liczba incydentów cyberbezpieczeństwa w latach 2015–2024

1.7 Częstość typów ataków w różnych branżach


Poniższa mapa ciepła przedstawia liczbę incydentów danego typu w podziale na branże. Kolor wskazuje intensywność ataków – im jaśniejszy odcień, tym więcej przypadków danego typu w danym sektorze. Najczęstsze ataki phishingowe występują głównie w bankowości i IT, co odzwierciedla podatność tych sektorów na socjotechniczne metody wyludzania danych. Z kolei DDoS i ransomware są szczególnie powszechne w sektorach IT i telekomunikacyjnym, co może wynikać z ich istotnej roli w infrastrukturze sieciowej. Różnice te pokazują, że dobór mechanizmów obronnych powinien być dostosowany do specyfiki branży.



Częstość typów ataków w różnych branżach

1.8 Rozkład strat finansowych według typu ataku


Na poniższym wykresie pudełkowym przedstawiono rozkład strat finansowych (w mln USD) przypisanych do różnych typów ataków cybernetycznych. Każde pudełko reprezentuje kwartyle rozkładu strat dla danego typu ataku, umożliwiając ocenę zmienności oraz typowego poziomu szkód. Widoczne jest, że największa rozpiętość strat występuje przy atakach typu DDoS oraz Man-in-the-Middle, co może wskazywać na dużą nieprzewidywalność skutków tych incydentów. Wszystkie typy ataków cechują się podobną medianą strat (ok. 50 mln USD), jednak różnice w kwartylach i długości wąsów pokazują, że skutki finansowe mogą się znacząco różnić w zależności od konkretnego przypadku.



Rozkład strat finansowych według typu ataku

1.9 Rozkład strat finansowych


Poniższy histogram przedstawia rozkład strat finansowych poniesionych w wyniku incydentów cyberbezpieczeństwa. Dodatkowo naniesiono wygładzoną linię gęstości, która pozwala lepiej ocenić rozkład wartości. Widzimy, że najwięcej incydentów generuje straty w przedziale od 40 do 60 milionów dolarów, co jest zgodne z wcześniej prezentowaną wartością średnią. Rozkład ten jest względnie symetryczny, z lekką tendencją do prawostronnej asymetrii – świadczy to o obecności kilku incydentów o wyjątkowo wysokich stratach.



Histogram strat finansowych (w mln USD) z nałożoną linią gęstości

1.10 Rozkład liczby poszkodowanych użytkowników

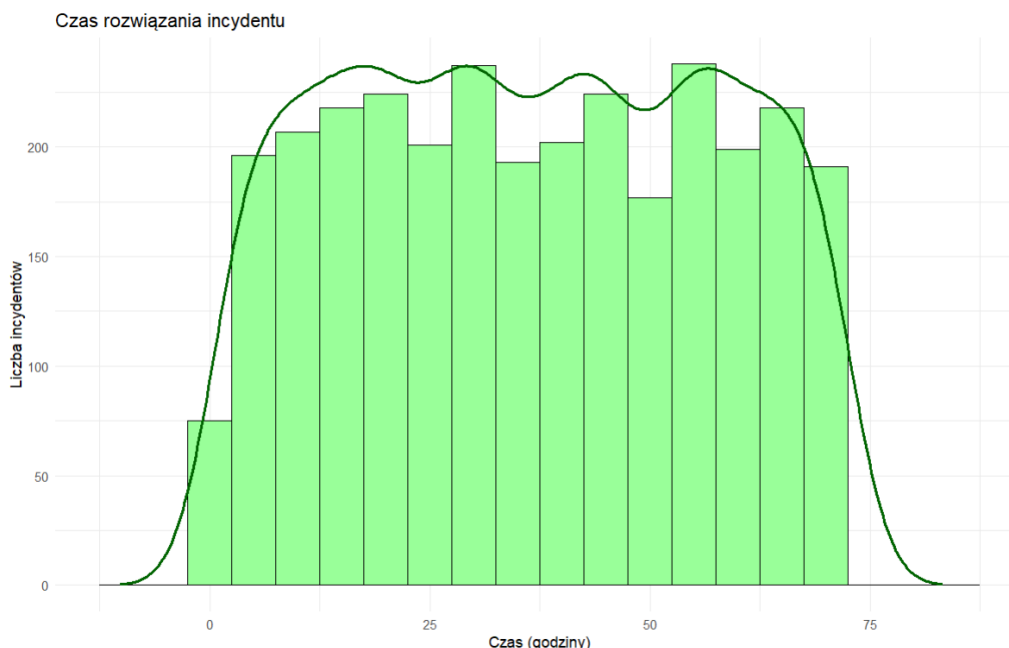
Histogram poniżej ilustruje rozkład liczby poszkodowanych użytkowników w wyniku incydentów cyberbezpieczeństwa. Widoczna jest znaczna zmienność – przypadki występują na całym spektrum, od kilkuset do niemal miliona użytkowników. Większość incydentów dotyczyła jednak liczby użytkowników w przedziale od 400 tys. do 700 tys. Rozkład ma względnie symetryczny kształt, co wskazuje na równomierne rozłożenie incydentów pod względem ich wpływu na użytkowników.



Histogram liczby poszkodowanych użytkowników z nałożoną linią gęstości

1.11 Rozkład czasu rozwiązania incydentu

Poniższy wykres przedstawia rozkład czasu (w godzinach), jaki upływa od wystąpienia incydentu do jego pełnego rozwiązania. Zauważalne jest, że większość incydentów została rozwiązana w przedziale 20–60 godzin. Wykres nie wykazuje wyraźnej asymetrii, ale występuje kilka przypadków, gdzie incydenty rozwiązano w czasie krótszym niż 10 godzin lub dłuższym niż 65 godzin. Może to sugerować istnienie zarówno dobrze przygotowanych zespołów reagowania, jak i sytuacji kryzysowych, które wymagały znacznie dłuższej interwencji.



Histogram czasu rozwiązania incydentu (w godzinach) z nałożoną linią gęstości

Przeprowadzona eksploracja danych pozwoliła uzyskać szczegółowy obraz struktury i charakterystyki incydentów cyberbezpieczeństwa w latach 2015–2024. Analiza wykazała dużą zmienność zarówno w skali strat finansowych, jak i w liczbie poszkodowanych czy czasie rozwiązania incydentów. Rozkłady wskazują na brak jednoznacznych trendów dominujących, co potwierdza, że incydenty mają różnorodny charakter i wymagają elastycznego podejścia w zakresie prewencji i reagowania. W kolejnych etapach możliwe będzie przeprowadzenie bardziej zaawansowanych analiz z wykorzystaniem metod statystycznych i uczenia maszynowego.

2 Cel projektu

Celem projektu jest analiza incydentów cyberbezpieczeństwa przy użyciu metod eksploracji danych. Zastosowano zarówno metody nienadzorowane (analiza skupień), jak i nadzorowane (drzewa decyzyjne), aby:

- wykryć naturalne grupy incydentów na podstawie cech ilościowych (np. liczby poszkodowanych, strat finansowych, czasu reakcji),
- lepiej zrozumieć charakterystykę i typologię ataków w różnych sektorach i lokalizacjach,
- przewidywać potencjalną wielkość strat finansowych na podstawie cech incydentu,
- wspomóc planowanie działań prewencyjnych i zarządczych w zakresie cyberbezpieczeństwa.

3 Wybór metody

W projekcie zastosowano dwie różne techniki analizy danych:

1. Grupowanie: Algorytm k-średnich

W celu wykrycia struktury wewnętrznej danych oraz powtarzalnych wzorców incydentów wykorzystano metodę **k-średnich (k-means)** — jedną z najpopularniejszych nienadzorowanych metod grupowania. Kluczowym etapem było dobranie liczby klastrów (k) na podstawie **metody łokcia**, która analizuje zmiany błędu grupowania w zależności od liczby grup.

2. Klasyfikacja: Drzewo decyzyjne

Do przewidywania poziomu strat finansowych wykorzystano metodę drzewa decyzyjnego (**rpart**). Jest to nadzorowana metoda uczenia maszynowego, która buduje hierarchiczną strukturę reguł decyzyjnych, pozwalających przypisać nowy incydent do jednej z klas: **High** (wysoka strata) lub **Low** (niewielka strata). Zalety tej metody to m.in. łatwa interpretacja oraz możliwość wyciągania logicznych wniosków z zależności między cechami a klasą docelową.

4 Zastosowanie metody do danych - k-średnich

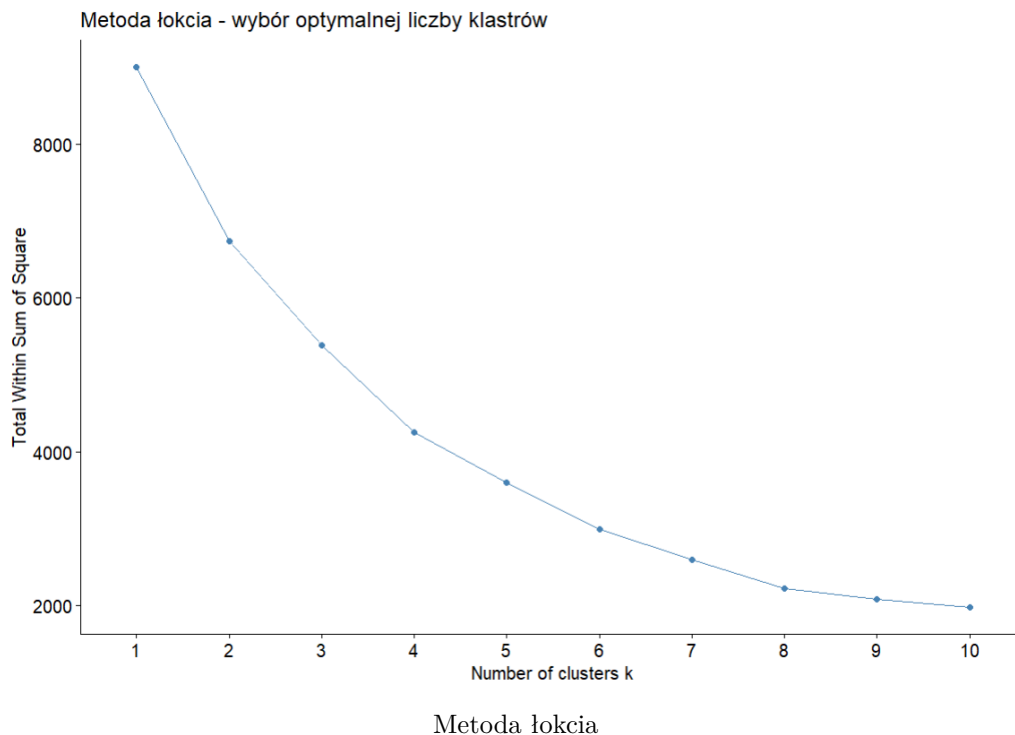
4.1 Przygotowanie danych

Przed zastosowaniem algorytmu k-średnich wykonano następujące kroki:

- usunięcie wartości brakujących oraz obserwacji niekompletnych,
- transformacja zmiennych kategorycznych (np. kraj, typ ataku) do formy liczbowej,
- standaryzacja danych cech ilościowych, aby zapewnić równy wpływ każdej cechy na proces grupowania.

4.2 Dobór liczby klastrów


W celu wyznaczenia optymalnej liczby klastrów zastosowano metodę łokcia. Wykres przedstawiono poniżej:



Na podstawie powyższego wykresu przyjęto wartość $k = 4$, gdzie zauważalny jest tzw. "łokieć", czyli miejsce, w którym dalsze zwiększanie liczby klastrów nie przynosi już istotnych korzyści w zmniejszeniu błędu grupowania.

4.3 Interpretacja klastrów

W wyniku przeprowadzenia grupowania metodą **k-średnich** oraz zastosowania metody łokcia ustalono liczbę klastrów na **cztery**. Następnie wykonano wizualizację przestrzenną klastrów z wykorzystaniem analizy głównych składowych (PCA) oraz obliczono statystyki opisowe dla każdej grupy.



Wizualizacja klastrow

Powyższy wykres przedstawia cztery wyraźnie wyodrębnione grupy incydentów cyberbezpieczeństwa. Na tej podstawie, w połączeniu ze statystykami opisowymi, można sformułować następujące wnioski:

- **Klaster 1 (czerwony)** – zawiera incydenty o *niskich stratach finansowych*, *krótkim czasie rozwiązania* oraz *niskiej liczbie dotkniętych użytkowników*. Może wskazywać na mniej poważne lub szybko neutralizowane ataki.
- **Klaster 2 (zielony)** – obejmuje incydenty o *wysokiej liczbie dotkniętych użytkowników* przy *umiarkowanych stratach finansowych*. Prawdopodobnie dotyczą ataków masowych, np. kradzieży danych.
- **Klaster 3 (niebieski)** – składa się z incydentów o *najwyższych stratach finansowych*, *długim czasie rozwiązania* i *średniej liczbie użytkowników*. Może wskazywać na ataki ransomware lub zaawansowane ataki APT.
- **Klaster 4 (fioletowy)** – zawiera incydenty o *niskiej liczbie użytkowników*, *długim czasie rozwiązania*, ale *średnich stratach finansowych*. Możliwe, że są to trudne do wykrycia lub ukierunkowane ataki (np. phishing ukierunkowany).

Połączenie wizualizacji z analizą liczbową pozwala nie tylko na określenie struktury danych, ale również na próbę przypisania charakteru poszczególnym grupom incydentów, co może posłużyć jako podstawa do dalszej klasyfikacji lub oceny ryzyka.

5 Zastosowanie drzewa decyzyjnego

Przygotowanie danych

Dla uproszczenia problemu klasyfikacji, zdefiniowano nową zmienną binarną `FinancialClass`, która przyjmuje wartości:

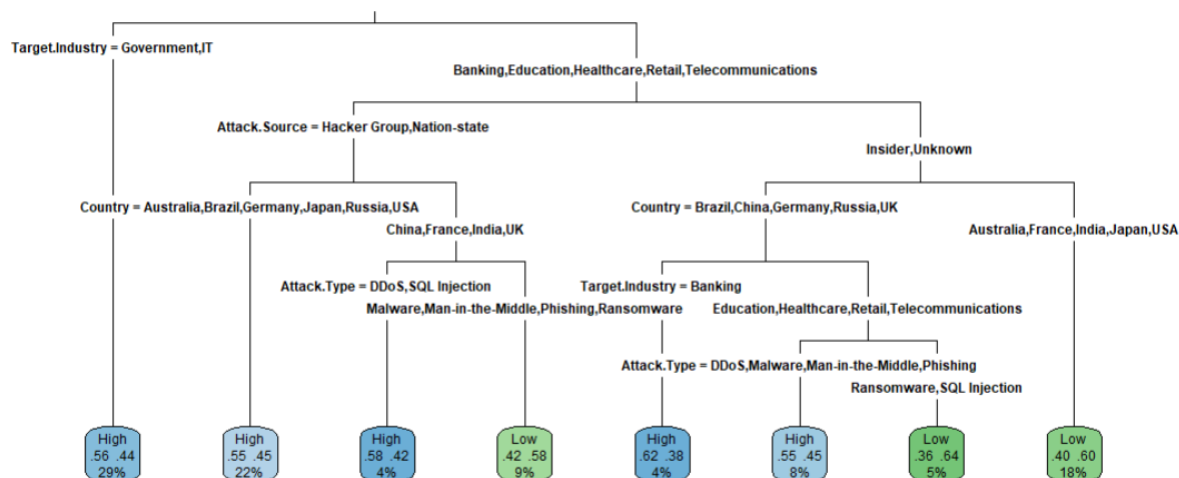
- **High**, jeśli straty przekraczają 50 milionów USD,
- **Low**, jeśli są równe lub niższe niż 50 milionów USD.

Z danych wybrano najistotniejsze zmienne predykcyjne: kraj, branżę celu, typ ataku, źródło ataku, czas rozwiązania incydentu i inne.

Budowa i walidacja modelu

Dane zostały podzielone na zbiór uczący (70%) oraz testowy (30%). Model drzewa decyzyjnego został wytrenowany z wykorzystaniem funkcji `rpart` i wizualizowany przy użyciu `rpart.plot`.

Drzewo decyzyjne: Strata finansowa



Drzewo decyzyjne dla klasyfikacji poziomu strat finansowych

Interpretacja modelu

Drzewo decyzyjne identyfikuje logiczne reguły wskazujące, czy incydent zakończy się dużą stratą finansową. Najważniejsze obserwacje:

- Ataki na sektor rządowy i IT mają większe prawdopodobieństwo zakończenia się wysokimi stratami.
- Zorganizowane źródła ataku (grupy hakerskie, państwa) częściej powodują kosztowne incydenty.
- Typ ataku (np. DDoS, phishing, ransomware) oraz kraj wystąpienia znacząco wpływają na poziom strat.

6 Podsumowanie i wnioski

Projekt dostarczył kompleksowej analizy globalnych incydentów cyberbezpieczeństwa z lat 2015–2024 z wykorzystaniem metod eksploracji danych. Przeprowadzona eksploracja umożliwiła dokładne zrozumienie struktury zbioru, identyfikację głównych trendów oraz zróżnicowania w obrębie typów ataków, branż i lokalizacji. Zastosowanie metod nienadzorowanych (k-średnich) oraz nadzorowanych (drzewa decyzyjne) pozwoliło na praktyczne wykorzystanie technik eksploracji danych w kontekście bezpieczeństwa cyfrowego.

Najważniejsze wnioski z eksploracji danych

- Liczba incydentów utrzymuje się na wysokim poziomie, z wyraźnymi wahaniami w zależności od roku, co może świadczyć zarówno o zmiennej intensywności ataków, jak i zmianach w zakresie ich wykrywalności.
- Najczęściej atakowane sektory to IT, bankowość i opieka zdrowotna, co wskazuje na konieczność szczególnej ochrony w tych branżach.
- *Phishing*, *ransomware* i *DDoS* pozostają dominującymi typami ataków – są skuteczne, masowe i trudne do pełnego zabezpieczenia.
- Rozkład strat finansowych oraz liczby poszkodowanych użytkowników cechuje się dużą zmiennością i asymetrią, co wskazuje na nieregularność skutków ataków – niektóre incydenty mają katastrofalne skutki, inne są relatywnie łagodne.
- Dane nie zawierają braków, co pozwoliło na pełne wykorzystanie ich potencjału analitycznego bez potrzeby imputacji.

Wnioski z grupowania (k-średnich)

- Udało się wyróżnić cztery wyraźne klastry incydentów, różniące się poziomem strat, liczbą ofiar i czasem reakcji.
- Klastry te odpowiadają różnym typom zagrożeń – od drobnych, szybko neutralizowanych incydentów, po zaawansowane i kosztowne ataki (np. *APT*, *ransomware*).
- Takie grupowanie może być wykorzystane w praktyce do szybkiej klasyfikacji nowego incydentu i przypisania go do odpowiedniego profilu ryzyka.

Wnioski z klasyfikacji (drzewo decyzyjne)

- Model drzewa decyzyjnego skutecznie przewiduje, czy incydent będzie wiązał się z wysokimi stratami finansowymi na podstawie jego cech ilościowych (czas, liczba użytkowników, typ ataku).
- Największy wpływ na poziom strat miały: czas rozwiązania, typ ataku oraz liczba poszkodowanych użytkowników.
- Prosty i czytelny model pozwala zrozumieć, jakie cechy incydentu stanowią sygnał alarmowy – co może pomóc w szybszym reagowaniu i lepszym zarządzaniu ryzykiem.

Zakończenie

Projekt pokazał, że eksploracja danych ma ogromny potencjał w kontekście cyberbezpieczeństwa – zarówno w analizie przeszłych zdarzeń, jak i w predykcji przyszłych zagrożeń. Użycie metod takich jak *k-średnich* i *drzewa decyzyjne* pozwala nie tylko zrozumieć złożone zjawiska, ale również przekształcić dane w praktyczne wskazówki dla organizacji i zespołów ds. bezpieczeństwa. W dobie rosnącej liczby ataków, analityka danych staje się nie tylko narzędziem wspomagającym, ale wręcz koniecznością w skutecznej ochronie przed cyberzagrożeniami.